

令和2年度学士論文

HTML5 字句解析仕様の 自然言語処理による意味解析

東京工業大学 情報理工学院 数理・計算科学系

学籍番号 17B01064

五十嵐彩夏

指導教員 南出靖彦 教授

提出日 1月18日

概要

概要. 概要. 概要. 概要. 概要. がいよう

目次

第 1 章	序論	1
第 2 章	準備	3
2.1	節, 品詞タグ	3
2.2	自然言語処理	3
第 3 章	HTML5 字句解析仕様	6
3.1	概要	6
3.2	字句解析器の動作の例	7
第 4 章	抽出の形式	9
4.1	抽出する命令の形式	9
4.2	例	12
第 5 章	自然言語処理	13
5.1	自然言語処理の対象	13
5.2	対象の前処理	13
5.3	Tag 型への変換	15
第 6 章	命令の抽出	18
6.1	Tag 型から Command への変換	18
6.2	If 文の処理	21
第 7 章	実装	22
7.1	概略	22
7.2	Env	22
7.3	Command 型	22
7.4	Bool 型	23
7.5	Token 型	23
7.6	Value	23
7.7	CommandValue 型	24
第 8 章	評価	25
8.1	HTML5 テスト	25

8.2 問題点	25
第 9 章 結論	27
参考文献	29

第 1 章

序論

自然言語は、人間が同士が互いにコミュニケーションをとるために発展してきた言語である。そして自然言語をコンピュータにて処理する技術を自然言語処理（Natural Language Processing）と呼んでいる。本論文では自然言語処理の技術を使って HTML5 の字句解析仕様から命令を抽出することを試みた。

HTML5 の構文解析の検証に関する研究には***がある。[8] [7] [3] それらの研究は自然言語によって書かれている仕様を手作業で抽出しているので、仕様の形式化を自動化したいと思った。仕様の形式化の自動化のメリットとしては、仕様の変更が行われることがあるため、その時に仕様の定式化を自動化していると嬉しい。

仕様書から自然言語処理を用いて命令抽出を試みた研究としては、機械語命令 ARM の仕様書を対象とした研究があり、自然言語処理の構文木解析の結果を用いて、命令の抽出を行っていた。[5]

実装では、自然言語処理のライブラリとして、スタンフォード大学によって提供されている Stanford CoreNLP [2] を使用した。

（何か書く）

図 1.1 が HTML5 の字句解析仕様の意味解析の概要である。

本論文では、まず 2 章で自然言語処理の基礎知識を述べる。次に 3 章で HTML5 の字句解析器の主な仕様、動作について述べる。4 章で抽出する命令の形式を BNF として述べ、5 章で自然言語処理ライブラリを用い、それを HTML5 字句解析仕様に適用させ、6 章で自然言語処理の出力をもとに仕様書の命令の抽出を行った。7 章で抽出した命令をもとに字句解析をするインタプリターを作成し、8 章で字句解析のテストデータを用い、抽出した命令の正しさを検証した。

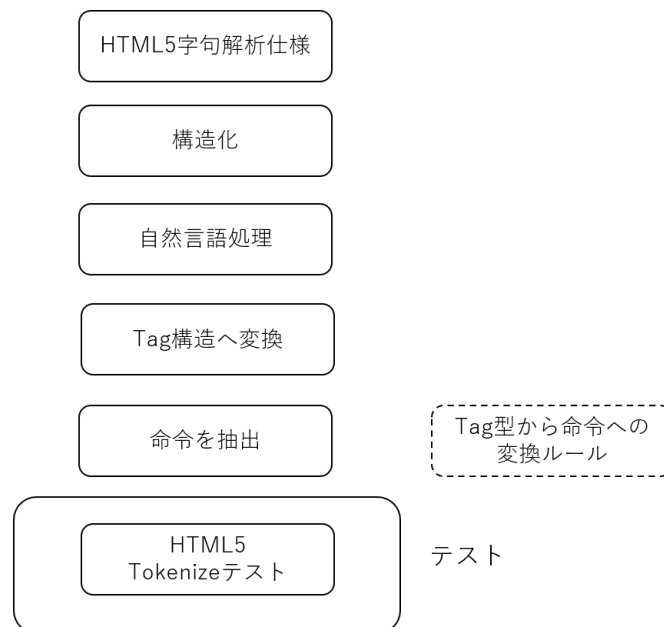


図 1.1 流れ（仮）

第 2 章

準備

2.1 節, 品詞タグ

いくつかの主要な節, 品詞タグの説明をする. [4]

節レベル

S : 節 ...

VP : 動詞句 ...

NP : 名詞句 ...

単語レベル

VB : 動詞 ...

NN : 名詞 ...

2.2 自然言語処理

自然言語処理とは, 自然言語で書かれている文章に対して, 形態素解析 (品詞タグ付け, 単語の原型の取得) や構文解析, 意味解析などをする処理である.

2.2.1 トークン分割, 品詞タグ付け, レンマ化

トークン化では, 文章を単語に分割する. 品詞タグ付けでは, その単語の品詞を調べる. レンマ化とは, 単語の原型を調べるものである.

例 1

Mika likes her dog's name.

これをトークン分割, 品詞タグ付け及びレンマ化をすると,

単語/品詞タグ : Mika/NNP likes/VBZ her/PRP\$ dog/NN 's/POS name/NN ./.


単語/原型 : Mika/Mika likes/like her/she dog/dog 's/'s name/name ./.

となる.

2.2.2 構文木解析

構文木解析とは、単語を節という単位でグループ化し、その構成を木構造で表現するものである。構文木解析をすることによって、文章の構造や単語同士のまとまりを調べることが出来る。

例 1 の “Mika likes her dog’s name.” を構文木解析すると、



のようになる。

2.2.3 係り受け解析

係り受け解析とは、節や単語間の関係を調べるものである。

目的語、修飾語などといったの単語や節の関係性を表す係り受けタグを使用し、それらを関連付ける。例えば、単語 B が単語 A の目的語である場合、 $A \xrightarrow{\text{目的語}} B$ という風に表記する。

例の、“Mika likes her dog’s name.” を係り受け解析すると、図 2.1 の様になり、“Mika” が好きなのは、“name”、“name” は “dog” の名前、“dog” は 彼女 (her) の犬であるという様に、単語の目的語、所有しているものを示してる単語が解析されている。




図 2.1 係り受け解析

2.2.4 固有表現抽出

固有表現抽出とは、文章内に数字や時間、アドレス、人間、地名を意味する単語があった場合、「この単語は地名を表すものである」という風に、固有な表現を解析するものである。

例 1 の “Mika likes her dog’s name.” の場合は、“Mika” が “人間” を表す単語であるということが固有表現抽出によって出力される。

2.2.5 参照関係の解析

参照関係の解析とは、文章内で同じものを指し示している単語が複数ある時、それらを関連付けさせ、抽出するものである。

これによって、“it” や “he” などの指示語の指し示すものを見つけることなどが出来る。

例 1 の “Mika likes her dog’s name.” の場合は、“Mika”, “her” が同一のものであることが参照関係の解析によって分かる。

第 3 章

HTML5 字句解析仕様

まず、自然言語処理の適用対象である、HTML5 の字句解析仕様について概要を述べていく。

3.1 概要

HTML5 字句解析仕様は WHATWG community の web サイトから得られる。[6]
HTML5 の字句解析器は 80 個の状態のあるオートマトンとして定義されており、それぞれの状態は以下の図 3.1 の形式で書かれている。

§	12.2.5.1 Data state
	Consume the <u>next input character</u> :
↪	U+0026 AMPERSAND (&) Set the <u>return state</u> to the <u>data state</u> . Switch to the <u>character reference state</u> .
↪	U+003C LESS-THAN SIGN (<) Switch to the <u>tag open state</u> .
↪	U+0000 NULL This is an <u>unexpected-null-character parse error</u> . Emit the <u>current input character</u> as a character token.
↪	EOF Emit an end-of-file token.
↪	Anything else Emit the <u>current input character</u> as a character token.

図 3.1 HTML5 字句解析仕様書（仮）なくていいかも

字句解析トークン

HTML5 字句解析器は、HTML5 で書かれている文章をその文法の構成単位であるトークンに分解するプログラムである。

HTML5 字句解析器により出力されるトークンは 5 つの種類がある。文書で利用する HTML や XHTML のバージョンを表すトークンである、DOCTYPE トークン (DOCTYPE token), “<!-- -->” などコメントアウトした文章を値として持つコメントトークン (comment token), ‘<’ と ‘>’ で囲まれている, HTML のタグを表す開始タグトークン (start tag token) と終了タグトークン (end tag token), 文字の情報を表す文字トークン (character token), 文章の終了を表す EOF トークン (end-of-file token) が存在する。

EOF トークン以外はそれぞれ値を持っている。

DOCTYPE トークンは DOCTYPE の名前, 公開識別子 (public identifier) とシステム識別子 (system identifier), 強制互換モードのフラグ (force-quirks flag) の要素を持っている。

開始, 終了タグトークンはタグの名前, 属性の集合 (attributes), セルフクロージングタグかどうかのフラグ (self-closing flag) の要素を持っている。

文字トークンは文字のデータを持つ。コメントトークンはコメント内容の文字列データを持つ。

具体的なトークンへの分解の例として, HTML5 文章

```
<!DOCTYPE html> <!-- ABCDEFG --> <p> hello </p>
```

をトークンに分解すると,

DOCTYPE トークン (名前: html, 公開識別子: null, システム識別子: null, 強制互換モードのフラグ: off)

コメントトークン (ABCDEFG)

開始タグトークン (名前: p, 属性: 無し, セルフクロージングタグのフラグ: off)

文字トークン (hello)

終了タグトークン (名前: p, 属性: 無し, セルフクロージングタグのフラグ: off)

となる。

字句解析器により出力されたトークンは DOM ツリーを構成する次の構文解析のステップに使われる。

字句解析器の環境の変数

HTML5 字句解析器は return state や一時バッファなどの様々な変数を持ち, 様々な命令により, 環境の変数の値を変化させていき, 動作する。

3.2 字句解析器の動作の例

3.2.1 例 1

入力 “<a>bc” に対して, HTML5 字句解析器は以下のように動作を行う。

1. 初期状態 Data state から, 文字‘<’が消費され, Tag open state に遷移する。
2. 文字‘a’を消費し, 名前が空文字である新たな開始タグトークンを作る。Tag name state に遷移する。
3. 先ほど消費した文字‘a’を再度消費し, 開始タグトークンの名前に‘a’を付け足す。
4. 文字‘>’を消費し, 開始タグトークンを排出し, Data state に遷移する。
5. 文字‘b’を消費し, 文字トークン (‘b’) を排出する。

6. 文字'c'を消費し、文字トークン('c')を排出する.
7. 文字'<'を消費し、Tag open state に遷移する.
8. 文字'/'を消費し、End tag open state に遷移する.
9. 文字'a'を消費し、名前が空文字である新たな終了タグトークンを作る. Tag name state に遷移する.
10. 先ほど消費した文字'a'を再度消費し、終了タグトークンの名前に'a'を付け足す.
11. 文字'>'を消費し、終了タグトークンを排出し、Data state に遷移する.
12. EOF トークンを排出する.

動作の結果として、

開始タグトークン (名前: "a", 属性: [], セルフクローズフラグ: off), 文字トークン ('b'), 文字トークン ('c'), 終了タグトークン (名前: "a"), EOF トークン
が順に排出される.

3.2.2 例 2

入力 "a<ab" に対して、HTML5 字句解析器は以下のように動作を行う.

1. 初期状態 Data state において、文字'a'を消費し、文字トークン('a')を排出する.
2. 文字'<'を消費し、Tag open state に遷移する.
3. 文字'a'を消費し、名前が空文字である新たな開始タグトークンを作る. Tag name state に遷移する.
4. 先ほど消費した文字'a'を再度消費し、開始タグトークンの名前に'a'を付け足す.
5. 文字'b'を消費し、開始タグトークンの名前に'b'を付け足す.
6. "eof-in-tag" 構文エラーを出す. EOF トークンを排出する.

動作の結果として、

"eof-in-tag" 構文エラーと、
文字トークン ('a'), EOF トークンが排出される.

第 4 章

抽出の形式

HTML5 の仕様書から命令を抽出するため, BNF の記法を用いて, 命令を形式化する.

4.1 抽出する命令の形式

まず命令の形式の, メタ変数, 型を以下で定める.

<code>cList</code>	: <code>CommandList</code>	... 命令文のリスト
<code>c</code>	: <code>Command</code>	... 命令文
<code>b</code>	: <code>Bool</code>	... if 文の命令文の条件部分の文
<code>cval</code>	: <code>CommandValue</code>	... 命令文が引数に持つ値
<code>ival</code>	: <code>ImplementVariable</code>	... 命令文が引数に持つ代入される変数の種類

メタ変数は, c_1, c_2 のように, 添え字つけられていてもよいものとする.

それぞれの型の構造は以下のように定める.

CommandList 型

$$\text{cList} ::= c :: \text{cList} \mid \text{Nil}$$

実際の実装では単に Scala の List 構造を用いている.

Command 型

```
c :: =   If(b, cList1, cList2)           // if b then cList1 else cList2
|   Ignore()                             // 何もしない処理
|   Switch(cval)                          // 状態 cval へ遷移する
|   Reconsume(cval)                      // 状態 cval へ遷移. この状態で消費した文字を, 次の状態で再度消費する.
|   Set(ival, cval)                       // ival に cval を代入する (ival ← cval)
|   AppendTo(cval, ival)                  // ival に cval を追加する (ival ← ival + cval)
|   Emit(cval)                           // トークン cval を排出する
|   Create(cval)                          // トークン cval を新たに作る
|   Consume(cval)                         // 文字 cval を消費する
|   Error(string)                        // エラー string を排出する
|   FlushCodePoint()                     // 一時バッファの内容を排出する
|   StartAttribute()                     // 現在の tagToken に新しい属性を加える
|   TreatAsAnythingElse()                // AnythingElse の処理内容を実行する
|   AddTo(cval, ival)                     // ival ← ival + cval
|   MultiplyBy(ival, cval)                // ival ← ival * cval
```

Bool 型

```
b :: =   And(b1, b2)                    // b1 かつ b2 である
|   Or(b1, b2)                          // b1 または b2 である
|   Not(b)                                // b でない
|   CharacterReferenceConsumedAsAttributeVal() // CharacterReferenceCode が属性の値として消費されているか
|   CurrentEndTagIsAppropriate()           // EndTagToken が適切なものであるか
|   IsEqual(cval1, cval2)                // cval1 と cval2 の値が等しい
|   AsciiCaseInsensitiveMatch(cval1, cval2) // cval1 と cval2 が文字列であるとき, 大文字, 小文字の差を無視し cval1 と cval2 の値が等しい
```

CommandValue 型

```
cval :: =  StateName(string)      // 状態名 string
          |  ReturnState           // return state
          |  TemporaryBuffer       // temporary buffer
          |  CharacterReferenceCode // character reference code
          |  NewStartTagToken       // 新しい start tag token
          |  NewEndTagToken         // 新しい end tag token
          |  NewDOCTYPEToken       // 新しい DOCTYPE token
          |  NewCommentToken       // 新しい comment token
          |  CurrentTagToken        // 一番新しく作られた tag token
          |  CurrentDOCTYPEToken    // 一番新しく作られた DOCTYPE token
          |  CurrentAttribute       // 一番新しく作られた attribute
          |  CommentToken           // 一番新しく作られた comment token
          |  EndOfFileToken         // end of file トークン
          |  CharacterToken(char)   // character token : char
          |  LowerCase(cval)        // cval の小文字
          |  NumericVersion(cval)   // 16 進数表記されている cval の数字としての値
          |  CurrentInputCharacter  // 現在消費した文字
          |  NextInputCharacter     // 入力文字列の一番最初の文字
          |  Variable(string)       // 変数 string
          |  CChar(char)           // Char 型の値 char
          |  CString(string)        // String 型の値 string
          |  CInt(int)              // Int 型の値 int
          |  CBool(boolean)        // Boolean 型の値 boolean
```

ImplementVariable 型

```
ival ::= IReturnState           // return state
      | ITemporaryBuffer       // 一時バッファ
      | ICharacterReferenceCode // character reference code
      | ICurrentTagToken        // 一番新しく作られた tag token
      | ICurrentDOCTYPEToken    // 一番新しく作られた DOCTYPE token
      | ICurrentAttribute       // 一番新しく作られた attribute
      | ICommentToken           // 一番新しく作られた comment token
      | IVariable(string)       // 変数 string
      | INameOf(ival)           // ival の名前
      | IValueOf(ival)          // ival の値
      | IFlagOf(ival)           // ival の flag
      | SystemIdentifierOf(ival) // ival の system identifier
      | PublicIdentifierOf(ival) // ival の public identifier
```

string,char,int,boolean はそれぞれ Scala の標準の型 (String,Char,Int,Boolean) の値

4.2 例

自然言語の文から, 上記の形式への変換の例をいくつか記す.

状態 Data_state へ遷移するという意味の文に関して,

Switch to the Data_state.

⇒ Switch(StateName(Data_state))

状態名を意味する StateName(Data_state) という CommandValue 型の値を持つ, Switch という遷移を意味する Command 型の値に変換する.

また, 現在のタグトークン名に, 現在消費した文字を小文字にしたものを付け足すという意味の文に関して,

Append the lowercase version of the current input character to the current tag token's tag name.

⇒ Append(LowerCase(CurrentInputCharacter), INameOf(CurrentTagToken))

第 1 引数に “現在消費した文字の小文字” を意味する CommandValue 型の値, 第 2 引数に “現在のタグトークン名” を意味する ImplementVariable 型の値を持つ Command 型の Append という値に変換される.

この自然言語の文章から上記の形式への変換の過程を 5, 6 章で説明していく.

第 5 章

自然言語処理

5.1 自然言語処理の対象

HTML5 の字句解析仕様には 80 個の状態があるが、本論文では字句解析仕様の自然言語処理する対象は 80 個のうち 77 個とした。

なぜなら 80 個の状態のうち、77 の状態は同じような構造で書かれているが、残りの 3 状態 (Markup declaration open state, Named character reference state, Numeric character reference end state) はそれぞれ特殊な構造で書かれている。これらも一括りにして自然言語処理を適用させるのは複雑になると判断し、自然言語処理の対象から除外した。

また、HTML5 仕様書内の Note や Example 等の補足説明は無視する。

尚、テストする際は残りの 3 つは手動で実装することにした。

5.2 対象の前処理

HTML5 字句解析仕様書は構造的に書かれている。

仕様書自体が構造的に書かれているので、仕様書解析の入力はその HTML のソースコードとした。

5.2.1 Scala 構造体

1 状態あたり、文字マッチング前の処理、状態名は “h5” タグ内にある。
文字マッチング前の処理は “h5” タグ直後の “p” タグ内に記述してある。
文字マッチングの処理は “dt”, “dd” タグ。

StateStructure

HTML5 字句解析仕様のオートマトンとしての状態を 1 つの単位として、Scala で定義した、StateStructure 構造体に変換する。


StateStructure 構造体は、状態名 name、最初の処理 prev、文字マッチングの処理 trans を持つ。仕様書の HTML ソースファイルの情報をこの構造にする。

5.2.2 文字列の置き換え

自然言語処理したい文章をそのまま処理すると、トークンの分割や品詞解析が適切な形で解釈されない。よって自然言語処理する際に、前処理として以下の文字列の置き換えをすることによって適切に文章が解釈されるようにした。

状態名の置き換え

Switch to the script data escape start state. の命令文が構文木解析において



と“script data escape”と“start state”が本来同じまとまりの中にあるべき単語がそれぞれ別のまとまりにいと解釈される。

よって状態名を1つのトークンとして扱われるようにし、適切に命令の文が解釈されるようにするため、次のような記法に置き換えることにした。

- ・空白、“-”を“_”にする。
- ・” (“,”)を除く。
- ・先頭を大文字にする。

例:

attribute value (double-quoted) state ⇒ Attribute_value_double_quoted_state

Unicode の置き換え

仕様書内では“U+xxxx”というユニコードが多用されている。これにそのまま自然言語処理を行うと、単語分割において“U”, “+xxxx”と2つのトークンに分割される。よってユニコード内の“+”を“_”に置き換えることによって1つのトークンとして認識させるようにした。

例:

“U+00AB” ⇒ “U_00AB”

動詞の置き換え

自然言語処理の結果を確認してみると、品詞解析の時点で動詞と認識されるべき単語が名詞扱いされることがあった。

例えば、“Reconsume” は “re” と “consume” の複合語であり、一般的な辞書にも載っていないので動詞として解釈されないことがあった。よってこのような単語の前に “you” という単語を付け加え、“you Reconsume …” とすることによって、“Reconsume” を動詞として解釈させるようにした。

また、Stanford CoreNLP は命令文の解釈が苦手である。よって特定の単語 (Switch, Reconsume, Emit, Flush, Append, Add, Multiply) の前に “you” という仮の主語を付け加え、命令文にならないようにする。

例:

“Switch to the data state.” ⇒ “you Switch to the data state.”

その他の置き換え

- “-” で繋がれている単語は 1 つのトークンとして認識されないため、“-” を “_” に置き換えた。
- 句読点をまたいでいる場合、参照関係の解析が上手くいかないことがあった。参照関係が多く出てくる Set 文に関して、“(,|.) set” ⇒ “and set” と置き換えをした。
- “!” が文末記号と認識されるため、“!” は “EXC” に置き換える。

5.3 Tag 型への変換

StanfordCoreNLP を用いての自然言語処理から得られる情報のうち、単語の原型の情報、構文解析の結果、参照関係の解析の結果を使用した。多分木の木構造のデータ型である Tag 型をプログラミング言語 Scala で定義し、それらの情報を Tag 型に変換した。

5.3.1 Tag 型

Tag 型は、Node 型と Leaf 型の 2 種類を持っている。Node 型は構文木の句を表すもので、句の種類を表す NodeType と、そのノードの子である Tag 型のリストを持つ。Leaf 型は構文木の末端である単語を表すもので、品詞名を表す LeafType と、単語の情報を格納する Token 型を持つ。Token 型は単語、単語の原型、参照関係の番号の情報を持つ。

Listing 5.1 Tag の定義

```
trait Tag
case class Node(node: NodeType, list: List[Tag]) extends Tag
case class Leaf(leaf: LeafType, token: Token) extends Tag
case class Token(word: String, lemma: String, coref: Int) extends Tag
trait NodeType
case object S extends NodeType
case object NP extends NodeType
case object VP extends NodeType
...
```

```
trait LeafType
case object NN extends LeafType
case object NNP extends LeafType
case object VB extends LeafType
...
```

5.3.2 Tag 型への変換

変換の対象として, “Create a token. Emit the token.” を例にとる.

構文木の処理

基本的には自然言語処理の構文木の出力の形を保った状態で木構造である Tag 型に変換するが, 例外的に以下の処理を加える.

1. -NP-PRP-“you” となっている部分を取り除く.
2. PRN ノード,“(” と “)” の間にあるノードを取り除く.
3. ドット (.) を取り除く.
4. 動詞を表す品詞は複数 (VB,VBZ,VBP...) あるが, それらは “VB” に統一する.

1 つ目は, 自然言語の前処理として適切な解釈がなされるように加えた “you” を取り除くためである. 2 つ目の処理は, カッコの中身を書いてある文章は補足説明が多く, 命令の抽出に必要ないと判断したためである. 3 つ目は, 既に自然言語処理の段階で文章の分割がなされており不要であるから, Tag 構造を簡潔なものにするため取り除く. 4 つ目は, 命令の抽出において, 単語が動詞かどうかを判断できれば十分であるので “VB” に統一することにした.

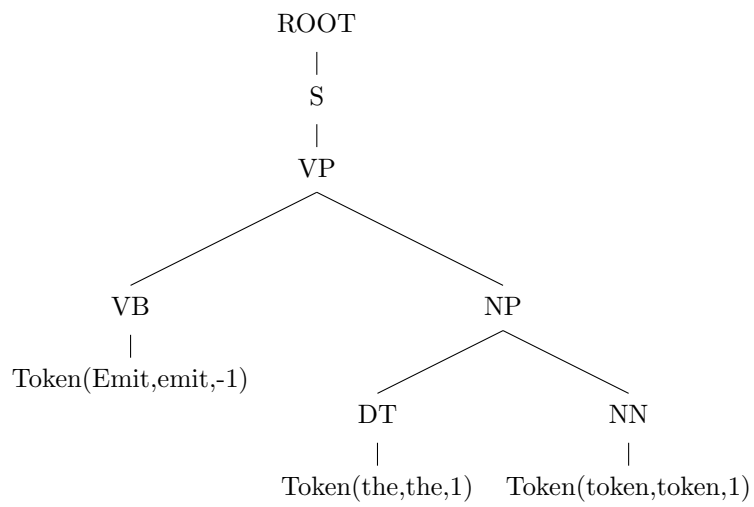

参照関係の処理

参照関係の出力として, $\text{CorefEntity} : 1 \Rightarrow [\text{a tag token, the token}]$ が出力される.

構文木を Tag 型に変換する際に, 参照関係を持っている単語の Token の参照番号をその番号とする. 参照関係を持たない単語に関しては参照番号を-1 とする.

変換後の Tag 構造

構文木の処理と参照関係の処理を行った結果.



第 6 章

命令の抽出

5 章において自然言語処理し, その結果を変換して得た Tag 型の情報を用いて, 4 章で定式化した形の命令の抽出を行う.

6.1 Tag 型から Command への変換


Tag 型の形に関してのパターンマッチングを用いて Command 型へ変換する. 文章, 動詞句, 名詞句 (Tag のノードが Node の Nodename が S, VP, NP) である場合に分け, 変換を行った. 葉の値はレンマ化された単語の情報のみ表記する.

6.1.1 文章 (S ノード) の変換

Nodename が S である Node から, Command 型のリストへ変換する関数を \mathcal{T}_S と置く.




\mathcal{T}_S は以下のパターンマッチを行い, マッチしたものに応じた CommandList を返す.

S の子ノードのリストの先頭が S ノードの場合, つまり Tag 型が




という木構造の形の時, $\mathcal{T}_S(\text{Node}(S, s1)) + \mathcal{T}_S(\text{Node}(S, rst1))$ を返す.

S の子ノードのリストの先頭が葉 “and”, カンマの場合, つまり Tag 型が



という木構造の形の時, $\text{commandList} \leftarrow \mathcal{T}_S(\text{Node}(S, rst1))$

S の子ノードのリストの先頭が VP ノードの場合, つまり Tag 型が



という木構造の形の時, $\text{commandList} \leftarrow \mathcal{T}_S(\text{Node}(\text{VP}, \text{vp1})) + \mathcal{T}_S(\text{Node}(\text{S}, \text{rst1}))$

(Node(VP, vp) に関して, 動詞句の変換を行う.)

If

Otherwise


6.1.2 動詞句の変換

Nodename が VP である Node(動詞句) から, Command 型のリストへ変換する関数を \mathcal{T}_{VP} と置く.
 \mathcal{T}_{VP} は以下のパターンマッチを行い, マッチしたものに応じた Command 型の List を返す.

Switch 文のマッチ

(元の文 : Switch to the ... state)


Tag の形が,



の時, $\text{Switch}(\langle \text{state} \rangle)$ を返す.

Reconsume 文


Reconsume in the ... state




$\rightarrow \text{Reconsume}(\langle \text{state} \rangle)$

Set 文


変数に値を代入する.



変数の状態を変える.



“Set the self-closing flag of the current tag token.” のような状態の切り替え先を示す “to on” が省略されている場合もあった. このような文の構文木は



となる. よってこの形にマッチした場合は, Set(<variable>, On) とさせた.

Emit 文

Emit 文

Emit 文


Emit 文

6.1.3 名詞句の変換

列挙の分解

名詞句には複数の名詞を and やカンマで区切っているものがある.


それを NP ノードのリストに分解した.



Set that attribute’s name and value のとこ手を加えた

that attribute’s は name と value どちらにも係っているので, この名詞句は that attribute’s name and that attribute’s value という解釈が正しい. しかし, 自然言語処理では that attribute’s は name にしか係ってい

ない風に解釈される。



CommandValue 型への変換

NP ノードを CommandValue 型に変換する際、単純に文字列に特定の単語が含まれているかどうかを調べるというやり方で実装した。

6.2 If 文の処理

If the temporary buffer is the string “script”, then switch to the script data escaped state. Otherwise, switch to the script data double escaped state. Emit the current input character as a character token.

どの部分の文章までが otherwise 文なのかが曖昧であった。手動で If 文の処理をしようと考えた。

第 7 章

実装

インタプリタを作成した.

7.1 概略

7.2 Env

```
next state
current state
return state
```

7.3 Command 型

実装した Command 型のそれぞれの動作を操作的意味論を用いて表す.

Switch(state: CommandValue)

$$\langle \text{Switch}(\text{state}), \text{env} \rangle \rightarrow \text{env}[\text{nextState} \leftarrow \mathcal{I}_{cval}[\![\text{state}]\!]]$$

Reconsume(state: CommandValue)

$$\begin{aligned} & \langle \text{Reconsume}(\text{state}), \text{env} \rangle \rightarrow \text{env}[\text{nextState} \leftarrow \mathcal{I}_{cval}[\![\text{state}]\!], \text{inputText} \leftarrow \text{char} + \text{inputText}] \\ \text{if currentInputCharacter} = \text{CharVal}(\text{char}) \\ & \langle \text{Reconsume}(\text{state}), \text{env} \rangle \rightarrow \text{env}[\text{nextState} \leftarrow \mathcal{I}_{cval}[\![\text{state}]\!], \text{inputText} \leftarrow \text{string} + \text{inputText}] \\ \text{if currentInputCharacter} = \text{StringVal}(\text{string}) \\ & \langle \text{Reconsume}(\text{state}), \text{env} \rangle \rightarrow \text{env}[\text{nextState} \leftarrow \mathcal{I}_{cval}[\![\text{state}]\!]] \\ \text{if currentInputCharacter} = \text{EOFVal} \end{aligned}$$

Consume()

Consume()

Consume()

Consume()

Consume()

Consume()

Consume()

Consume()

Consume()

Consume()

If(bool: Bool, t: CommandList, f: CommandList)

$$\frac{\langle \text{clist1}, \text{env} \rangle \rightarrow \text{env}'}{\langle \text{if } b \text{ then clist1 else clist2}, \text{env} \rangle \rightarrow \text{env}'} \text{ if } \mathcal{B}[\![b]\!] = \text{true}$$
$$\frac{\langle \text{clist2}, \text{env} \rangle \rightarrow \text{env}'}{\langle \text{if } b \text{ then clist1 else clist2}, \text{env} \rangle \rightarrow \text{env}'} \text{ if } \mathcal{B}[\![\mathcal{C}[b]]\!] = \text{false}$$

7.4 Bool 型

And(a: Bool, b: Bool)

CharacterReferenceConsumedAsAttributeVal()

CurrentEndTagsAppropriate()

IsEqual(a: CommandValue, b: CommandValue)

7.5 Token 型

tagToken(isStart: Boolean, name: String, attributes: List[Attribute]) DOCTYPEToken(systemIdentifier: String, publicIdentifier: String) characterToken()

7.6 Value

CharVal(c: Char) StringVal(string: String) EOFVal StateVal(statename: String) TokenVal(token: Token)

7.7 CommandValue 型

CommandValue 型から Value 型の値を返す関数

$C : \text{CommandValue} \rightarrow \text{Value}$

LowerCaseVersion(cVal: CommandValue)

c.toLowerCase if $C[\llbracket \text{cVal} \rrbracket] = c$: Char or String

NumericVersion(cVal: CommandValue)

Integer.parseInt(c.toString, 16)

NextInputCharacter

$$\begin{cases} \text{CharVal}(c) & \text{inputText.headOption} = \text{Some}(c) \\ \text{EOFVal} & \text{inputText.headOption} = \text{None} \end{cases}$$

CurrentInputCharacter

currentInputCharacter

EndOfFileToken

TokenVal(endOfFileToken())

第 8 章

評価

8.1 HTML5 テスト

字句解析のインタプリターの正しさを検証するために,html5lib-tests [1] の tokenizer のテストデータを用い,テストを行った.

テスト結果

テストファイル名	結果	テスト内容
contentModelFlags.test	24/24	あ
domjs.test	42/58	あ
entities.test	80/80	あ
escapeFlag.test	9/9	あ
namedEntities.test	4210/4210	あ
numericEntities.test	336/336	あ
pendingSpecChanges.test	1/1	あ
test1.test	63/68	あ
test2.test	35/45	あ
test3.test	1374/1786	あ
test4.test	81/85	あ
unicodeChars.test	323/323	あ
unicodeCharsProblem.test	5/5	あ

8.2 問題点

test2.test,test3.test,test4.test が上手くいかなかった原因

If the six characters starting from the current input character are an ASCII case-insensitive match for the word “PUBLIC”, then consume those characters この文章を自然言語解析させると “those characters” は “the six characters starting from the current input character” を参照するという出力になる.

もし、この状態へ遷移した時点での入力文字列が “public …” であったら、まず文字’p’を消費し、入力文字列が “ublic …” となる。

機械的にこの文章を処理しようとする、現在の入力文字列 “ublic …” から文字列 “public” を消費せよという解釈になるので、上手くいかない。

この問題を手動で解決させた結果、以下のようなテスト結果の改善が成された。

テストファイル名	結果
test2.test	45/45
test3.test	1786/1786
test4.test	85/85

第 9 章

結論

命令の種類が限られており、それぞれ決まった書き方をしていることが多かったので、構文木の情報のみでも命令の抽出が可能だった。(機械的な文字のマッチングでも出来そうではあった.)

しかし今回はやらなかったが、特に命令の記法が一貫していない場合は係り受け解析を用いたほうが様々な形式の文章に対応できるので良いと思われる。

例えば、Tag 型から命令の型である Command 型へ変換する際、構文木のマッチングで、“Emit the current input character as a character token.” といった文がある。この文のように “current input character” に “as a character token” のような補足的な情報が加わると、複数種類のパターンマッチ文を書く必要が出てきており、命令抽出の対象の記法が比較的一貫したので煩雑さは抑えられたが、係り受け解析を用いたほうが簡潔にできると感じた。that attribute’s は name と value

謝辭

謝辭. 謝辭. 謝辭. 謝辭.

参考文献

- [1] James Graham, Geoffrey Sneddon, et al. html5lib-tests, 2020. <https://github.com/html5lib/html5lib-tests>.
- [2] Christopher D. Manning, Mihai Surdeanu, John Bauer, Jenny Finkel, Steven J. Bethard, and David McClosky. The Stanford CoreNLP natural language processing toolkit. In *Association for Computational Linguistics (ACL) System Demonstrations*, pages 55–60, 2014.
- [3] Yasuhiko Minamide and Shunsuke Mori. Reachability analysis of the html5 parser specification and its application to compatibility testing. *FM 2012: Formal Methods*, 2012.
- [4] Jeanette Pettibone. Penn treebank II tags, 2020. <https://web.archive.org/web/20130517134339/http://bulba.sdsu.edu/jeanette/thesis/PennTags.html>.
- [5] Anh V. Vu and Mizuhito Ogawa. Formal semantics extraction from natural language specifications for arm. *Formal Methods–The Next 30 Years*, 2019.
- [6] WHATWG. Html standard, 2020. <https://html.spec.whatwg.org/multipage/parsing.html>.
- [7] 小林 孝広. 交代性オートマトンを用いたトランスデューサの包含関係の保守的検査. 東京工業大学 学士論文, 2019.
- [8] 芹田 悠一郎. トランスデューサによる XSS Auditor の有効性の分析. 東京工業大学 学士論文, 2017.